



UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE  
CENTRO DE CIÊNCIAS EXATAS E DA TERRA  
DEPARTAMENTO DE INFORMÁTICA E MATEMÁTICA APLICADA  
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO



# Processamento de dados com Apache Spark e Storm: Uma visão sobre e-Participação nas Cidades Inteligentes brasileiras

Felipe Cordeiro Alves Dias

Natal-RN  
Junho, 2016

Felipe Cordeiro Alves Dias

**Processamento de dados com Apache Spark e Storm:  
Uma visão sobre e-Participação nas Cidades  
Inteligentes brasileiras**

Monografia de Graduação apresentada ao Departamento de Informática e Matemática Aplicada do Centro de Ciências Exatas e da Terra da Universidade Federal do Rio Grande do Norte como requisito parcial para a obtenção do grau de bacharel em Engenharia de Software.

Orientador

Nélio Alessandro Azevedo Cacho, doutor

UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE – UFRN  
DEPARTAMENTO DE INFORMÁTICA E MATEMÁTICA APLICADA – DIMAP

Natal-RN

Junho, 2016

Monografia de Graduação sob o título *Processamento de dados com Apache Spark e Storm: Uma visão sobre e-Participação nas Cidades Inteligentes brasileiras* apresentada por Felipe Cordeiro Alves Dias e aceita pelo Departamento de Informática e Matemática Aplicada do Centro de Ciências Exatas e da Terra da Universidade Federal do Rio Grande do Norte, sendo aprovada por todos os membros da banca examinadora abaixo especificada:

---

Titulação e nome do(a) orientador(a)  
Orientador(a)  
Departamento  
Universidade

---

Titulação e nome do membro da banca examinadora  
Co-orientador(a), se houver  
Departamento  
Universidade

---

Titulação e nome do membro da banca examinadora  
Departamento  
Universidade

---

Titulação e nome do membro da banca examinadora  
Departamento  
Universidade

Natal-RN, data de aprovação (por extenso).

Agradeço a Deus por todas as oportunidades, pelo apoio da minha amada esposa, Laísa  
Dias Brito Alves; família e amigos. Todos especialmente importantes para mim.

# Agradecimentos

Agradeço a toda a minha família pelo incentivo e apoio recebidos; aos professores do curso de Engenharia de Software com os quais tive aprendizados importantes para a minha vida acadêmica, profissional e pessoal. Também, ao professor Nélcio Alessandro Azevedo Cacho, pela orientação, apoio e confiança. No demais, a todos que direta ou indiretamente fizeram parte da minha formação.

*Queremos ter certezas e não dúvidas, resultados e não experiências, mas nem mesmo percebemos que as certezas só podem surgir através das dúvidas e os resultados somente através das experiências.*

Carl Gustav Jung

# Processamento de dados com Apache Spark e Storm: Uma visão sobre e-participação nas Cidades Inteligentes brasileiras

Autor: Felipe Cordeiro Alves Dias

Orientador: Doutor Nélio Alessandro Azevedo Cacho

## RESUMO

O resumo deve apresentar de forma concisa os pontos relevantes de um texto, fornecendo uma visão rápida e clara do conteúdo e das conclusões do trabalho. O texto, redigido na forma impessoal do verbo, é constituído de uma seqüência de frases concisas e objetivas e não de uma simples enumeração de tópicos, não ultrapassando 500 palavras, seguido, logo abaixo, das palavras representativas do conteúdo do trabalho, isto é, palavras-chave e/ou descritores. Por fim, deve-se evitar, na redação do resumo, o uso de parágrafos (em geral resumos são escritos em parágrafo único), bem como de fórmulas, equações, diagramas e símbolos, optando-se, quando necessário, pela transcrição na forma extensa, além de não incluir citações bibliográficas.

*Palavras-chave:* Palavra-chave 1, Palavra-chave 2, Palavra-chave 3.

# Data Processing with Apache Spark and Storm: A vision on e-participation in Brazilian Smart Cities

Author: Felipe Cordeiro Alves Dias

Advisor: Nélío Alessandro Azevedo Cacho, Doctor

## ABSTRACT

O resumo em língua estrangeira (em inglês *Abstract*, em espanhol *Resumen*, em francês *Résumé*) é uma versão do resumo escrito na língua vernácula para idioma de divulgação internacional. Ele deve apresentar as mesmas características do anterior (incluindo as mesmas palavras, isto é, seu conteúdo não deve diferir do resumo anterior), bem como ser seguido das palavras representativas do conteúdo do trabalho, isto é, palavras-chave e/ou descritores, na língua estrangeira. Embora a especificação abaixo considere o inglês como língua estrangeira (o mais comum), não fica impedido a adoção de outras linguas (a exemplo de espanhol ou francês) para redação do resumo em língua estrangeira.

*Keywords:* Keyword 1, Keyword 2, Keyword 3.



# Lista de figuras

1	Cidade num invólucro digital . . . . .	p. 19
2	Principais propriedades de Confiança . . . . .	p. 23
3	Ilustração da arquitetura em pilha do Apache Spark . . . . .	p. 24
4	Componentes do Spark para execução distribuída . . . . .	p. 26
5	Ilustração da arquitetura do Apache Storm . . . . .	p. 29
6	Ilustração de uma topologia do Storm . . . . .	p. 31
7	Ilustração de um DStream . . . . .	p. 35
8	Ilustração de um fluxo de processamento no Flink . . . . .	p. 35
9	Ilustração de um stream particionado no Samza . . . . .	p. 36
10	Diagrama de classes da aplicação desenvolvida para processamento e coleta de métricas relacionadas a e-Participação . . . . .	p. 38
11	Diagrama do mapeamento entre um Resilient Distributed Dataset de Long para Double . . . . .	p. 39
12	Diagrama do mapeamento entre um Resilient Distributed Dataset de Datas para suas respectivas frequências em Double . . . . .	p. 40

# Lista de tabelas

1	Quantidade de citações a plataformas ESPs por referência . . . . .	p. 36
2	Contas do Twitter relacionadas as prefeituras municipais das capitais dos vinte e sete estados brasileiros . . . . .	p. 41

# Lista de abreviaturas e siglas

IoT – Internet of Things

ONU – Organização das Nações Unidas

TICs – Tecnologias da Informação e Comunicação

RTC – Real Time Computing

ESP – Event Stream Processing

CEP – Complex Event Processing

POSET – Partially ordered set of events

FIFO – First In, First Out

DStream – Discretized Stream

RDD – Resilient Distributed Dataset

DAG – Directed Acyclic Graph

SNR – Social Network Ratio

UFRN – Universidade Federal do Rio Grande do Norte

DIMAp – Departamento de Informática e Matemática Aplicada

YARN – Yet Another Resource Negotiator

# Sumário

<b>1</b>	<b>Introdução</b>	p. 14
1.1	Objetivo . . . . .	p. 15
1.2	Organização do trabalho . . . . .	p. 16
<b>2</b>	<b>Fundamentação Teórica</b>	p. 17
2.1	Cidades Inteligentes . . . . .	p. 17
2.1.1	Internet das Coisas . . . . .	p. 18
2.1.2	Requisitos de uma aplicação de Cidade Inteligente . . . . .	p. 19
2.1.3	e-Participação . . . . .	p. 20
	Níveis de e-Participação. . . . .	p. 21
2.2	Plataformas de processamento em tempo real . . . . .	p. 22
2.2.1	Processamento de fluxo de eventos em tempo real . . . . .	p. 23
2.3	Apache Spark . . . . .	p. 24
2.3.1	Módulos do Apache Spark . . . . .	p. 25
2.3.2	Composição Interna do Apache Spark . . . . .	p. 25
	2.3.2.1 Modelo de execução das aplicações Spark . . . . .	p. 26
	2.3.2.2 Job . . . . .	p. 27
	2.3.2.3 Stage . . . . .	p. 27
	2.3.2.4 Task . . . . .	p. 28
2.4	Apache Storm . . . . .	p. 29
2.4.1	Composição interna do Apache Storm . . . . .	p. 29
	2.4.1.1 Nimbus . . . . .	p. 30

2.4.1.2	Supervisor node . . . . .	p. 30
2.4.1.3	ZooKeeper . . . . .	p. 30
2.4.1.4	Topologia . . . . .	p. 31
	Bolt. . . . .	p. 31
	Spout. . . . .	p. 32
<b>3</b>	<b>Definição e execução do estudo de caso</b>	p. 34
3.1	Metodologia de escolha das plataformas para processamento de fluxo de eventos em tempo real . . . . .	p. 34
	Apache Spark Streaming. . . . .	p. 34
	Apache Flink. . . . .	p. 35
	Apache Storm. . . . .	p. 35
	Apache Samza. . . . .	p. 35
3.2	Aplicações desenvolvidas para estudo de caso . . . . .	p. 37
3.2.1	Aplicação para processamento de tweets e coleta de métricas relacionadas a e-Participação . . . . .	p. 37
3.2.2	Aplicação Web . . . . .	p. 40
<b>4</b>	<b>Capítulo 4</b>	p. 42
4.1	Seção 1 . . . . .	p. 42
4.2	Seção 2 . . . . .	p. 42
<b>5</b>	<b>Capítulo 5</b>	p. 43
5.1	Seção 1 . . . . .	p. 43
5.2	Seção 2 . . . . .	p. 43
5.2.1	Subseção 5.1 . . . . .	p. 43
5.2.2	Subseção 5.2 . . . . .	p. 43
5.3	Seção 3 . . . . .	p. 43

<b>6</b>	<b>Considerações finais</b>	p. 44
	<b>Referências</b>	p. 45
	<b>Apêndice A – Primeiro apêndice</b>	p. 48
	<b>Anexo A – Primeiro anexo</b>	p. 49

# 1 Introdução

Hoje em dia, o crescimento populacional tem sido uma das fontes de stress sob a infraestrutura e recursos de uma cidade (CLARKE, 2013), fenômeno conhecido também como Tragédia dos comuns (HARDIN, 1968), no qual há um cenário de alta demanda por determinados recursos finitos, os quais explorados nessa escala se tornam escassos. Levando isso em consideração, Cidades Inteligentes, são aquelas que, principalmente, usam novas tecnologias para transformar seus sistemas e otimizar o uso de recursos finitos, melhorando a eficiência da economia, possibilitando desenvolvimento político, social, cultural e urbano (SAÉZ-MARTÍN; ROSSARIO; CABA-PEREZ, 2014).

No contexto de Cidades Inteligentes, alguns objetos do nosso cotidiano têm a capacidade de serem conectados à Internet através de eletrônicos embarcados, sensores e software, formando a Internet das Coisas IoT (Internet of Things) . Em 2013, menos de 1% desses dispositivos estavam conectados, sendo a previsão para 2020 de 212 bilhões. Quanto a pessoas conectadas à Internet, prevê-se 3.5 bilhões em 2017, sendo 64% via dispositivos móveis (CLARKE, 2013).

Tal volume de dados, dobrará a cada dois anos até 2020 (EMC, 2014), principalmente devido ao crescimento do uso da Internet, smartphones e Redes Sociais; a queda do custo de equipamento para criar, capturar, administrar, proteger e armazenar informação; migração da TV analógica para a digital; crescimento dos dados gerados por máquinas, incluindo imagens de câmeras de segurança e da informação sobre informação (CLARKE, 2013).

Sendo assim, de acordo com essa expansão, chegar-se-á um patamar em que tudo o que é possível estar, estará conectado, ampliando o conceito de Internet das Coisas para o de Internet de Todas as Coisas, segundo a Cisco (CISCO, 2016). Com essa quantidade de pessoas e dispositivos conectados, cerca de 44 trilhões de gigabytes serão gerados (EMC, 2014), os quais processados por sistemas inteligentes, ajudarão no surgimento de serviços de grande impacto no cotidiano de uma cidade (CLARKE, 2013).

Portanto, umas das principais problemáticas abordadas por Cidades Inteligentes é a de processamento de grande volume dados, provenientes dos sensores instalados em tubulações de água, avenidas (para controle de congestionamentos), iluminações públicas; de câmeras de segurança; da análise de Redes Sociais, como o processamento de tweets (mensagem publicada ou trocada pelos utilizadores da rede social Twitter (INFOPIEDIA, 2016)), etc.

Analisando o conteúdo das Redes Sociais, por exemplo, é possível explorar o nível de interação entre cidadãos e governos locais no âmbito digital (e-Participação). Sendo essa exploração algo importante por a população ser um componente fundamental das Cidades Inteligentes, que tem como função principal servi-la. Devido a isso, ambas as partes precisam ter uma comunicação ativa (SAÉZ-MARTÍN; ROSSARIO; CABA-PEREZ, 2014).

Apesar dessa importância, poucos trabalhos tem sido direcionados a exploração do potencial das Redes Sociais para as Cidades Inteligentes (SAÉZ-MARTÍN; ROSSARIO; CABA-PEREZ, 2014), principalmente no que diz respeito a e-Participação (MACIEL; ROQUE; GARCIA, 2009). Além disso, os rankings de Cidades Inteligentes, normalmente, adotam critérios relacionados a transparência e existência de serviços eletrônicos, ignorando o uso de outras ferramentas para Governo Eletrônico, como as Redes Sociais (SAÉZ-MARTÍN; ROSSARIO; CABA-PEREZ, 2014).

## 1.1 Objetivo

Tendo o que foi exposto anteriormente em consideração, essa monografia tem como objetivo desenvolver uma aplicação para realizar processamento de tweets, coletando métricas relacionadas a e-Participação, das cidades brasileiras ranqueadas, recentemente, como Cidades Inteligentes (Connected Smartcities, 2015), exibindo essas informações numa aplicação web contendo um mapa, buscando obter uma visão do nível de participação, no âmbito digital, entre o governo local e os cidadãos, comparando-a com o ranking mencionado.

O processamento desses tweets, assim como de outros dados, pode ser feito usando, por exemplo, Processamento de Fluxo de Eventos (ESP - Event Stream Processing), processando enventos (acontecimentos do mundo real ou digital) na ordem em que eles chegam, ou, via Processamento Complexo de Eventos (CEP - Complex Event Processing), entendendo como esses eventos se relacionam, dentre outros aspectos, construindo padrões para identificá-los num fluxo de eventos (LUCKHAM, 2006).



A escolha entre essas abordagens depende dos requisitos da aplicação. E, para o objetivo dessa monografia, a abordagem de ESP se mostrou mais adequada, pois os tweets serão processados em ordem. Então, a partir disso, foi desenvolvida uma metodologia para selecionar duas plataformas para ESP, sendo o Apache Spark e Storm escolhidas, principalmente, devido ao número de citações que ambas possuem em artigos e na comunidade de software. Ainda, esse trabalho também tem como proposta comparar as ferramentas citadas, tendo como estudo de caso a aplicação a ser desenvolvida.

## 1.2 Organização do trabalho

Nesta seção deve ser apresentado como está organizado o trabalho, sendo descrito, portanto, do que trata cada capítulo.

## 2 Fundamentação Teórica

Nesse capítulo, são apresentados os conceitos relacionados a essa monografia, os quais estão divididos nas seguintes seções: 2.1, sobre a temática de Cidades Inteligentes; 2.2, a respeito de Plataformas de processamento em tempo real; 2.3 e 2.4, sobre o Apache Spark e Storm, respectivamente.

### 2.1 Cidades Inteligentes

Projeções da Organização das Nações Unidas (ONU) , indicam que a população mundial urbana atual passará de 3.9 bilhões de pessoas para 6.3 bilhões em 2050, representando 66% do total de habitantes, 9.54 bilhões (ONU, 2014). Tal crescimento populacional tem tido consequências graves como a miséria; sendo pertencente a classe de problemas de solução não técnica, de acordo com o fenômeno conhecido por Tragédia dos Comuns, no qual uma alta demanda de recursos finitos (água, energia, alimentos, estradas, etc.) os tornam escassos (HARDIN, 1968).

A ONU, por sua vez, indicam algumas estratégias políticas para lidar com esse problema, tais como: incentivo a migração interna; redistribuição espacial da população; expansão da infraestrutura; garantia de acesso a serviços e oportunidades de trabalho; uso de Tecnologias da Informação e Comunicação (TICs) , para melhoraria na entrega de serviços (ONU, 2014), etc. Podendo nesse último ponto, por exemplo, haver exploração das TICs visando a implantação de iniciativas relacionadas a Cidades Inteligentes.

As Cidades Inteligentes são locais nos quais, principalmente, busca-se transformar os sistemas da cidade e otimizar o uso de seus recursos finitos, melhorando assim a eficiência da economia, possibilitando desenvolvimento político, social, cultural e urbano (SAÉZ-MARTÍN; ROSSARIO; CABA-PEREZ, 2014). Apesar dessas possíveis transformações e otimizações, é importante salientar, novamente, que nenhuma abordagem técnica resolve por si só as problemáticas decorrentes do crescimento populacional (HARDIN, 1968).

Uma das problemáticas que as Cidades Inteligentes ajudam a resolver é a de demanda por eficiência energética (decorrente das mudanças climáticas), que requer das cidades menos emissão de gás carbono, podendo isso ser obtido utilizando iluminação pública, com investimentos em prédios sustentáveis (energeticamente sustentável e com uso de áreas verdes), transportes públicos e ciclovias. Outra possibilidade, é o de desenvolvimento de serviços digitais capazes de ajudar os cidadãos com questões cotidianas, como achar um táxi, saber a localização de um ônibus, encontrar a rota com menos congestionamento de carros, reportar crimes, comunicar-se com o governo, etc.

O problema relacionado a Cidades Inteligentes tratado por essa monografia, como já mencionado, insere-se no contexto de processamento de grande volume de dados, o qual é devido, principalmente a conexão de objetos conectados à Internet (contexto de IoT, conceito explicado em 2.1.1), com previsão de existirem 212 bilhões até 2020. E, também, ao aumento do número de pessoas conectas (o que com o crescimento populacional tende a aumentar), prevendo-se 3.5 bilhões em 2017, sendo 64% via dispositivos móveis (CLARKE, 2013).

Ainda, mais especificamente, espera-se que a quantidade de dados existentes dobre a cada dois anos até 2020 (EMC, 2014). Outros fatores que tem contribuído para isso são: o crescimento do uso da Internet, smartphones e Redes Sociais; a queda do custo de equipamento para criar, capturar, administrar, proteger e armazenar informação; migração da TV analógica para a digital; crescimento dos dados gerados por máquinas, incluindo imagens de câmeras de segurança e da informação sobre informação (CLARKE, 2013).

### 2.1.1 Internet das Coisas

Considerando o exposto pela seção 2.1, a expansão de pessoas e coisas conectadas à Internet, chegar-se-á um patamar em que tudo o que é possível estar, estará conectado, ampliando o conceito de Internet das Coisas para o de Internet de Todas as Coisas, segundo a Cisco (CISCO, 2016). Em tal cenário, cerca de 44 trilhões de gigabytes serão gerados (EMC, 2014), os quais processados por sistemas inteligentes, ajudarão no surgimento de serviços de grande impacto no cotidiano de uma cidade (CLARKE, 2013).

Principalmente, aqueles que monitoram e reportam continuamente qualquer modificação que ocorra em um determinado cenário. Por exemplo, no contexto de saúde pública, é possível monitorar as condições do organismo de um paciente, notificando os médicos responsáveis caso a pessoa esteja em risco, através de uma rápida comunicação e resposta a tal acontecimento. Alguns dos sistemas semelhantes a esse são exemplificados na Fig. 1.

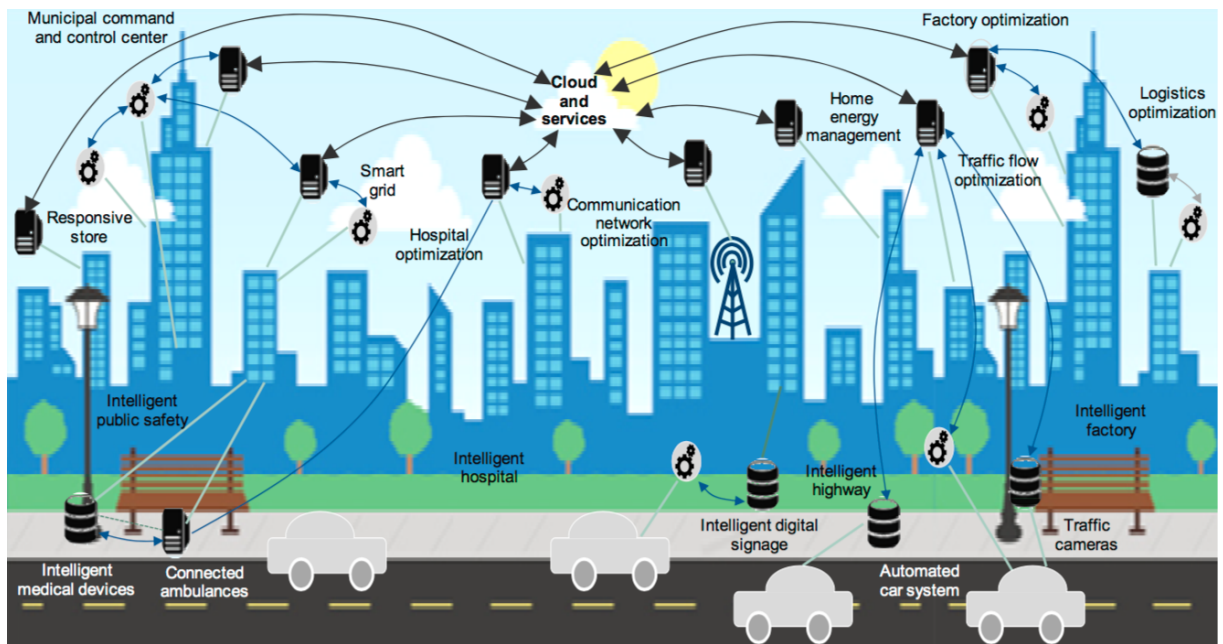


Figura 1: Cidade num invólucro digital

**Fonte:** (CLARKE, 2013)

Na Fig. 1, organizações, pessoas e objetos estão conectados, criando um invólucro digital, composto por representações de serviços conectados a nuvem, tais como: o de um (i) Hospital Inteligente, conectado a dispositivos médicos inteligentes e a ambulâncias; (ii) Centro Digital de Controle e Comando Municipal, integrado a um sistema inteligente de segurança pública e armazenamento de dados; (iii) Sistema de Otimização de Fluxo de Tráfego, conectado a um sistema de estradas inteligentes agregadas a câmeras de controle de tráfego; (iv) Fábrica Inteligente, integrada a um sistema de otimização de logística e fábrica; (v) Administração de Energia Doméstica e (vi) Smart Grid (um novo modelo de Redes Elétricas (H. et al., 2016)) e (vii) Otimização de Rede de Comunicação.

Tais serviços não serão estudados nesse trabalho, foram apenas referenciados visando demonstrar uma pequena parte da gama de possibilidades existentes em Cidades Inteligentes, Internet das Coisas, e a problemática relacionada ao processamento de dados.

### 2.1.2 Requisitos de uma aplicação de Cidade Inteligente

Ante a variedade de fontes de dados disponíveis, conforme mencionado na seção 2.1.1, a capacidade de processar grandes volumes de dados pode ser um dos requisitos necessários a uma aplicação de Cidade Inteligente. Normalmente, duas métricas são utilizadas para analisar esse requisito: os valores de (i) throughput e (ii) latência. O primeiro termo se refere a taxa de processamento (Techopedia, 2016) e, o segundo a variação do tempo entre

um estímulo e resposta (Techopedia, 2016).

Dependendo do contexto da aplicação, o valor da latência tem maior relevância sobre o de throughput. Por exemplo, a latência talvez seja mais interessante de ser priorizada quando respostas a determinados eventos precisam ser no menor intervalo de tempo possível (menos de um segundo). Por outro lado, as aplicações que priorizam throughput, podem apenas necessitarem processar grandes volumes de dados dentro de um valor de latência aceitável (no máximo alguns segundos).

Outro requisito importante, é o de tolerância a falhas (necessário quando a aplicação está inserida em ambientes distribuídos, ou, de incertezas), o qual permite o funcionamento do sistema mesmo que uma falha ocorra, o que pode ser obtido, por exemplo, por meio de replicação (COULOURIS et al., 2013). Além disso, pode existir a necessidade de atender o requisito de escalabilidade, através do qual é possível oferecer um serviço de alta qualidade conforme o aumento da demanda, adicionando novos recursos (escalabilidade horizontal), ou, melhorando os existentes (escalabilidade vertical) (SOMMERVILLE, 2011).

Além disso, a aplicação pode precisar do requisito de processamento em tempo real, no qual há um limite de tempo pré-determinado para as respostas aos eventos do sistema (SOMMERVILLE, 2011). Por fim, é importante também avaliar as ferramentas que serão utilizadas no desenvolvimento da aplicação quanto ao suporte aos requisitos citados e as abstrações que elas dispõem.

### **2.1.3 e-Participação**

Uma das temáticas abordadas em Cidades Inteligentes, é a de promover novos meios para a participação do cidadão com questões relacionadas a gestão da cidade (SAÉZ-MARTÍN; ROSSARIO; CABA-PEREZ, 2014). Essa interação pode ser feita através de Redes Sociais, que são compostas por um conjunto de pessoas (ou, organizações), representando nós de uma rede, sendo a conexão entre eles conhecida como relacionamento (MACIEL; ROQUE; GARCIA, 2009).

Sendo assim, tal ambiente virtual, tem proporcionado um novo espaço para que os cidadãos possam participar de processos de consulta e deliberação (exame e discussão de um assunto (PRIBERAM, 2016)), atuando com os governos como atores de processos de tomadas de decisão (MACIEL; ROQUE; GARCIA, 2009). Além das Redes Sociais, a participação pode ocorrer em outros ambientes virtuais, tais como aplicativos, wiki, fórum, blogs, dentre outros (MAGALHÃES, 2015), resumindo-se em e-participação, conceito inserido no

de Governo Eletrônico.

O Governo Eletrônico é caracterizado pelo uso de TICs pelo governo público, buscando prover melhores serviços, informações e conhecimento ao cidadão; facilitando o acesso ao processo político e incentivando a participação (MAGALHÃES, 2015). Ele pode ser dividido, principalmente, nos três campos seguintes: e-Administração, a respeito do funcionamento interno do poder público; e-Governo, no tocante a entrega e fornecimento de serviços e informações qualificadas aos cidadãos; e-Democracia, relacionada a ampliação da participação da sociedade na tomada de decisão, sendo a e-Participação uma subárea desse último (MAGALHÃES, 2015).

A intenção da e-Participação é reforçar e renovar as interações entre o setor público, os políticos e cidadãos; tanto quanto possível no processo democrático (MAGALHÃES, 2015). Além disso, a e-Participação não pode ser avaliada somente por seus aspectos técnicos, mas também quanto a capacidade de incrementar a democracia (MAGALHÃES, 2015).

Um dos desafios nessa área é avaliar as ferramentas apoiadas pelas TICs, quanto as formas de engajamento existentes, como informação, consulta, ou, participação ativa (MAGALHÃES, 2015). Ainda, segundo citação contida em (MAGALHÃES, 2015), a e-Participação é um conjunto de várias tecnologias, medidas sociais e políticas, havendo a necessidade de melhorar a compreensão das relações entre esses componentes e como suas respectivas práticas de avaliação podem ser aplicadas a e-Participação como um todo.

Com isso, para que os processos que a envolvem sejam eficazes é importante considerar os ambientes online e off-line, ou seja, incrementando os métodos tradicionais (conferências, fóruns, conselhos, ouvidorias, audiências, consultas, reuniões, comitês, grupos de trabalho e mesas de negociação) com as possibilidades da e-Participação, estendendo-a ainda aos grupos desfavorecidos e desconectados (MAGALHÃES, 2015). Por fim, no parágrafo seguinte, são referenciados alguns dos diferentes níveis de e-Participação.

**Níveis de e-Participação.** No nível e-Informação, há um canal unidirecional, visando apenas fornecer informações de interesse cívico; no de e-Consulta, a comunicação é bide-reccional, via coleta de opiniões e alternativas; no de e-Envolvimento busca-se garantir a compreensão e levar em consideração os anseios do cidadão; em e-Colaboração, a comunicação é bidireccional, e o cidadão participa ativamente no desenvolvimento de alternativas e indentificação de melhores soluções; por fim, no de e-Empoderamento, a influência, controle e elaboração de políticas pelo e para o público é viabilizada (MAGALHÃES, 2015).

## 2.2 Plataformas de processamento em tempo real

As plataformas de processamento em tempo real (RTC, Real Time Computing) , compostas por hardware ou software, são sistemas que tem como um dos principais requisitos emitir respostas a eventos de acordo com um determinado deadline (limite de tempo). Sendo assim, a correteza da computação não depende apenas da correteza lógica, mas também dos resultados serem produzidos de acordo com o deadline especificado (SHIN; RAMANATHAN, 1994), (SOMMERVILLE, 2011).

Normalmente, os resultados são obtidos através de processamentos realizados por um conjunto de tasks (tarefas) cooperativas, iniciadas por eventos do sistema. Os eventos são dependentes do ambiente no qual estão inseridos, podendo ocorrer periodicamente (de forma regular e previsível), ou, aperiodicamente (irregulares e imprevisíveis) (SHIN; RAMANATHAN, 1994), (SOMMERVILLE, 2011).

As tasks podem ter uma relação de interdependência e ao mesmo tempo nem todos os eventos que as originaram necessitam de ser processados dentro de um deadline. Apesar disso, nenhuma task pode vir a comprometer o processamento de outra (SHIN; RAMANATHAN, 1994).

Com isso, os deadlines podem ser classificados em hard, firm, ou, soft. No primeiro caso, respectivamente, as respostas a todos os eventos devem necessariamente ocorrer dentro do deadline definido; no segundo, deadlines esporadicamente não atendidos são aceitos; no terceiro, deadlines não alcançados são permitidos frequentemente (SHIN; RAMANATHAN, 1994). Além dessas categorias, há os sistemas com delay (atraso) introduzido entre o intervalo de tempo de estímulo e resposta, os quais são classificados como near real time (NRT), ou seja, são sistemas de processamento em "quase tempo real".

Sendo assim, na categoria hard, é considerado como falha se o tempo estimado para um processamento não for atendido, e nas demais, a ocorrência disso resulta numa degradação (contínua de acordo com a quantidade de deadlines não atendidos) (SHIN; RAMANATHAN, 1994), (SOMMERVILLE, 2011).

Entende-se por falha quando o usuário não recebe algo esperado (por exemplo, deadline não atendido) devido a um erro de sistema. Sendo esse erro um estado errôneo resultante de um defeito (característica do sistema que pode resultar em erro). E, degradação, como decréscimo da qualidade (conceito subjetivo, de acordo com os requisitos da aplicação) do sistema (SOMMERVILLE, 2011).

Por fim, é importante mencionar também que uma falha de sistema pode comprometer o requisito de Confiança e prejudicar um grande número de pessoas (SHIN; RAMANATHAN, 1994), (SOMMERVILLE, 2011). Na Fig. 2 a seguir, são ilustradas as principais propriedades desse requisito:

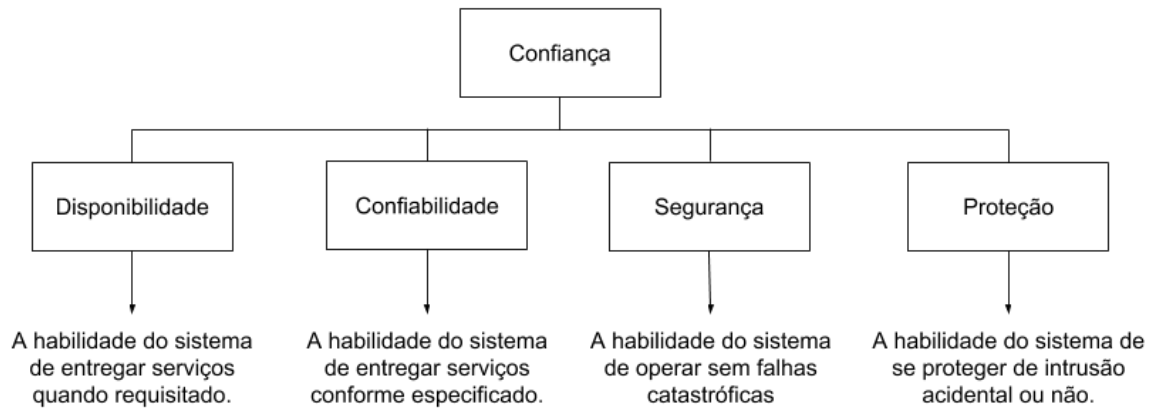


Figura 2: Principais propriedades de Confiança

**Fonte:** (SOMMERVILLE, 2011)

### 2.2.1 Processamento de fluxo de eventos em tempo real

Fluxo (ou stream) de eventos, basicamente, pode ser entendido como uma série de eventos em função do tempo (NARSUDE, 2015), (LUCKHAM, 2006). Dentro desse escopo, duas abordagens de processamento são importantes diferenciar: (i) ESP (Event Stream Processing, ou, Processamento de Fluxo de Eventos) e (ii) CEP (Complex Event Processing, ou, Processamento Complexo de Eventos). A primeira, costuma-se focar principalmente com questões de baixo nível, relacionadas a como processar eventos em tempo real atendendo requisitos de escalabilidade, tolerância a falha, confiabilidade, etc (KLEPPMANN, 2015).

Na segunda abordagem, os streams são utilizados para criar uma nuvem de eventos, parcialmente ordenados por tempo e causalidade, conceito conhecido como POSET (Partially ordered set of events) (LUCKHAM, 2006). Sendo assim, normalmente, visa-se trabalhar questões de alto nível, utilizando posets para a criação de padrões de eventos, envolvendo seus relacionamentos, estrutura interna, etc. Com esse conjunto de informações é possível compor eventos complexos, os quais podem ser consultados continuamente (KLEPPMANN, 2015).

Portanto, nessa monografia, será utilizada a primeira abordagem (ESP) para proces-



samento de eventos, por ser mais adequada ao objetivo proposto no Cap. 1. Em ESPs, algumas plataformas processam os streams continuamente conforme são recebidos pelo sistema; paradigma conhecido como One at time. Quando um evento é processado com sucesso, há a possibilidade de emitir uma notificação sobre isso, a qual é custosa por ser necessário rastreá-lo até o término de seu processamento (NARSUDE, 2015).

Outra alternativa, é a de realizar o processamento em micro-batches (pequenos lotes) de eventos, tendo com uma das vantagens poder realizar operações em pequenos blocos de dados, em vez de individualmente, ao custo de introduzir um pequeno atraso no processo (NARSUDE, 2015).

## 2.3 Apache Spark

Apache Spark é uma plataforma de computação em cluster (unidade lógica composta por um conjunto de computadores conectados entre si através da Rede, permitindo compartilhamento de recursos (Techopedia, 2016)), com suporte a consultas a banco de dados, processamento de streaming (em near real time), grafos, e aprendizado de máquina. Tendo Java, Python e Scala como linguagens de programação suportadas (Apache Software Foundation, 2016f).

A arquitetura do Spark, conforme a Fig. 3, é composta por uma pilha integrando os seguintes componentes, a serem explicados posteriormente: Spark SQL, Spark Streaming, MLib, GraphX, Spark Core e Administradores de Cluster (Yarn (Apache Software Foundation, 2016c) e Apache Mesos (Apache Software Foundation, 2016d)). Tal estrutura visa ser de fácil manutenção, teste, deploy, e permitir aumento de performance do núcleo impactando seus demais componentes.




Figura 3: Ilustração da arquitetura em pilha do Apache Spark

**Fonte:** (KARAU et al., 2015)

### 2.3.1 Módulos do Apache Spark

O Spark Core é o principal módulo do Apache Spark, responsável principalmente pelo gerenciamento de memória, tasks (conceito explicado em 2.3.2.4) e tolerância a falha. Ainda nele, a abstração conhecida como RDD é definida, cujo papel é o de representar uma coleção de dados distribuídos e manipulados em paralelo. Os RDDs em Java são representados pela classe `JavaRDD`, criados através da classe `JavaSparkContext` (contexto da aplicação), que é instanciada recebendo como parâmetro um objeto `SparkConf`, contendo informações relacionadas ao nome da aplicação e o endereço em que ela será executada, podendo ser local, ou, em cluster.

Outro módulo é o Spark Streaming, o qual realiza o processamento de dados em stream. Os streams são representados por uma sequência de RDDs, conhecida como DStream. O contexto de um streaming (`JavaStreamingContext`) é criado usando as configurações da aplicação e o intervalo no qual cada DStream será definido. Após isso, tais streams são atribuídos a um objeto da classe `JavaReceiverInputDStream`.

Além dos módulos detalhados nos parágrafos anteriores, é relevante mencionar o (i) Spark SQL, responsável por trabalhar com dados estruturados; o (ii) MLib, relacionado ao aprendizado de máquina, contendo algoritmos tais como o de classificação, regressão, "clusterização", filtragem colaborativa, avaliação de modelo e importação de dados; e o (iii) GraphX, que é composto por uma biblioteca para manipulação de grafos e computações paralelas. Por fim, o Spark também possui um administrador de cluster padrão, conhecido como Standalone Scheduler (Apache Software Foundation, 2016f), tendo também suporte ao YARN e Apache Mesos.

### 2.3.2 Composição Interna do Apache Spark

Nesta seção é explicada a composição interna do Apache Spark, expondo os componentes que permitem a execução distribuída de uma aplicação spark, tais como o Driver Program, Spark Context, Worker Node e Executor. Também são explicados os conceitos sobre as operações de Transformação e Ação, e os relativos a Job, Stage, Task e Partição RDD.

### 2.3.2.1 Modelo de execução das aplicações Spark

O modelo de execução das aplicações Spark é definido pela relação composta por um driver, SparkContext, executors e tasks, conforme ilustrado na Fig. 4. Nessa interação, as aplicações Spark funcionam num Worker Node (qualquer nó capaz de executar código de aplicação localmente ou num cluster) como uma espécie de Driver, o qual executa operações paralelas e define dados distribuídos sobre um cluster. Além disso, o driver é responsável por encapsular a função principal da aplicação e prover acesso ao Spark, utilizando o objeto da classe SparkContext. Tal objeto é usado também para representar uma conexão com um cluster e construir RDDs (KARAU et al., 2015).

Após a construção de um RDD, é possível executar operações sobre ele. Essas operações são realizadas por executors, processos administrados por uma aplicação Spark (cada aplicação tem os seus próprios executors); nos quais há espaços reservados para execução de tasks (conceito explicado na seção 2.3.2.4). Há dois tipos de operações: (i) Ações (actions) e (ii) Transformações (transformations) (Apache Software Foundation, 2016f). O primeiro tipo retorna um resultado ao driver após computações sobre um conjunto de dados de acordo com uma função. Sendo o segundo, responsável por gerar novos conjuntos de dados (RDDs) através, também, de funções especificadas (KARAU et al., 2015).




Figura 4: Componentes do Spark para execução distribuída

**Fonte:** (KARAU et al., 2015)

### 2.3.2.2 Job

A abstração do conceito de job está relacionada com o de action. Mais especificamente, um job é o conjunto de estágios (stages) resultantes de uma determinada action. Por exemplo, quando o método `count()` é invocado (para realizar a contagem de elementos dentro de um RDD), cria-se um job composto por um ou mais estágios. Os jobs, por padrão, são escalonados para serem executados em ordem FIFO (First In, First Out). Além disso, o scheduler do Spark é responsável por criar um plano de execução física, o qual é utilizado para calcular as RDDs necessárias para executar a ação invocada (KARAU et al., 2015), (XU; JU; REN, 2015).

Em tal plano de execução física, defini-se basicamente um grafo acíclico dirigido (DAG), relacionando as dependências existentes entre os RDDs, numa espécie de linhaagem de execução (lineage). Após isso, a partir da última RDD do último estágio, cada dependência é calculada, de trás para frente, para que posteriormente os RDDs dependentes possam ser calculados, até que todas as actions necessárias tenham terminado (KARAU et al., 2015), (XU; JU; REN, 2015).

### 2.3.2.3 Stage

A divisão de um job resulta no conceito de stage, ou seja, jobs são compostos por um ou mais stages, os quais têm tasks a serem executadas. Nem sempre a relação entre stages e RDDs será de 1:1. No mais simples dos casos, para cada RDD há um stage, sendo possível nos mais complexos haver mais de um stage gerado por um único RDD (KARAU et al., 2015), (XU; JU; REN, 2015).

Por exemplo, havendo três RDDs no grafo RDD, não necessariamente haverá três stages. Um dos motivos para isso acontecer é quando ocorre pipelining, situação na qual é possível reduzir o número de stages, calculando os valores de alguns RDDs utilizando unicamente informações de seus antecessores, sem movimentação de dados de outros RDDs (KARAU et al., 2015), (XU; JU; REN, 2015).

Além da possibilidade do número de stages ser reduzido, o contrário acontece quando fronteiras entre stages são definidas. Tal situação ocorre porque algumas transformações, como a `reduceByKey` (função de agregação por chaves), podem resultar em reparticionamento do conjunto de dados para a computação de alguma saída, exigindo dados de outros RDDs para a formação de um único RDD. Assim, em cada fronteira entre os stages, tasks do estágio antecessor são responsáveis por escrever dados para o disco e buscar

tasks no estágio sucessor, através da rede, resultando em um processo custoso, conhecido como shuffling (KARAU et al., 2015), (XU; JU; REN, 2015).

O número de partições entre o estágio predecessor e sucessor podem ser diferentes, sendo possível customizá-lo, embora isso não seja recomendável. Tal aconselhamento é devido ao fato de que se o número for modificado para uma pequena quantidade de partições, tais podem sofrer com tasks overloaded (sobrecarregadas), do contrário, havendo partições em excesso, resultará em um alto número de shuffling entre elas (KARAU et al., 2015), (XU; JU; REN, 2015).

Em resumo, shuffling sempre acontecerá quando for necessário obter dados de outras partições para computar um resultado, sendo esse um procedimento custoso devido ao número de operações de entrada e saída envolvendo: leitura/escrita em disco e transferência de dados através da rede. No entanto, se necessário, o Spark provê uma forma eficiente para reparticionamento, conhecida como coalesce(), a qual reduz o número de partições sem causar movimentação de dados (KARAU et al., 2015).

#### 2.3.2.4 Task

A abstração do conceito task está relacionada principalmente com stage, pois, uma vez que os estágios são definidos, tasks são criadas e enviadas para um scheduler interno. Além disso, tasks estão muito próximas da definição de partition, pelo fato de ser necessária a existência de uma task para cada partition, para executar as computações necessárias sobre ela (KARAU et al., 2015).

Portanto, o número de tasks em um stage é definido pelo número de partições existentes no RDD antecessor. E, por outro lado, o número de partições em um determinado RDD é igual ao número de partições existentes no RDD do qual ele depende. No entanto, há exceções em caso de (i) coalescing, processo o qual permite criar um RDD com menos partições que seu antecessor; (ii) união, sendo o número de partições resultado da soma do número de partições predecessoras; (iii) produto cartesiano, produto dos predecessores (KARAU et al., 2015).

Cada task internamente é dividida em algumas etapas, sendo elas: (i) carregamento dos dados de entrada, sejam eles provenientes de unidades de armazenamento (caso o RDD seja um RDD de entrada de dados), de um RDD existente (armazenado em memória cache), ou, de saídas de outro RDD (processo de shuffling), (ii) processamento da operação necessária para computação do RDD representado por ela, (iii) escrever a saída para o

processo de shuffling, para um armazenamento externo ou para o driver (caso seja o RDD final de uma ação). Em resumo, uma task é responsável por coletar os dados de entrada, processá-los e, por fim, gerar uma saída (KARAU et al., 2015).

## 2.4 Apache Storm

Apache Storm (Apache Software Foundation, 2016g) é uma plataforma de computação em cluster, com suporte a processamento de stream de dados em tempo real. O Storm requer pouca manutenção, é de fácil de administração e tem suporte a qualquer linguagem de programação (que leia e escreva fluxos de dados padronizados), posto que em seu núcleo é utilizado o Apache Thrift (Apache Software Foundation, 2016h) (framework que permite o desenvolvimento de serviços multilinguagem) para definir e submeter topologias (conceito definido em 2.4.1.4) (Apache Software Foundation, 2016g).

A arquitetura do Storm, conforme a Fig. 5, é composta pelos seguintes componentes, a serem explicados posteriormente: Nimbus, ZooKeeper e Supervisor Node.




Figura 5: Ilustração da arquitetura do Apache Storm

**Fonte:** (JAIN; NALYA, 2014)

### 2.4.1 Composição interna do Apache Storm

Nesta seção é explicada a composição interna do Apache Storm, expondo os principais componentes que permitem a execução distribuída de uma topologia Storm, tais como o Nimbus, ZooKeeper e Supervisor nodes.

#### 2.4.1.1 Nimbus

Nimbus é o processo master executado num cluster Storm, tendo ele uma única instância e sendo responsável por distribuir o código da aplicação (job) para os nós workers (computadores que compõem o cluster), aos quais são atribuídas tasks (parte de um job). As tasks são monitoradas pelo Supervisor node, sendo reiniciadas em caso de falha e quando requisitado. Ainda, caso um Supervisor node falhe continuamente, o job é atribuído para outro nó worker (JAIN; NALYA, 2014), (HART; BHATNAGAR, 2015).

O Nimbus utiliza um protocolo de comunicação sem estado (Stateless protocol), ou seja, cada requisição é tratada individualmente, sem relação com a anterior, não armazenando dados ou estado (Techopedia, 2016), sendo assim todos os seus dados são armazenados no ZooKeeper (definido em 2.4.1.3). Além disso ele é projetado para ser fail-fast, ou seja, em caso de falha é rapidamente reiniciado, sem afetar as tasks em execução nos nós workers (JAIN; NALYA, 2014), (HART; BHATNAGAR, 2015).

#### 2.4.1.2 Supervisor node

Cada Supervisor node é responsável pela administração de um determinado nó do cluster Storm; gerenciando o ciclo de vida de processos workers relacionados a execução das tasks (partes de uma topologia) atribuídas a ele próprio. Os workers quando em execução emitem "sinais de vida"(heartbeats), possibilitando o supervisor detectar e reiniciar caso não estejam respondendo. E, assim como o Nimbus, um Supervisor node é projetado para ser fail-fast (JAIN; NALYA, 2014), (HART; BHATNAGAR, 2015).

#### 2.4.1.3 ZooKeeper

O ZooKeeper Cluster (Apache Software Foundation, 2016i) é responsável por coordenar processos, informações compartilhadas, tasks submetidas ao Storm e estados associados ao cluster, num contexto distribuído e de forma confiável, sendo possível aumentar o nível de confiabilidade tendo mais de um servidor ZooKeeper. O ZooKeeper atua também como o intermediário da comunicação entre Nimbus e os Supervisor nodes, pois eles não se comunicam diretamente entre si, ambos também podem ser finalizados sem afetar o cluster, visto que todos os seus dados, são armazenados no ZooKeeper, como já mencionado anteriormente (JAIN; NALYA, 2014), (HART; BHATNAGAR, 2015).

#### 2.4.1.4 Topologia

A topologia Storm, ilustrada na Fig. 6, é uma abstração que define um grafo acíclico dirigido (DAG), utilizado para computações de streams. Cada nó desse grafo é responsável por executar algum processamento, enviando seu resultado para o próximo nó do fluxo. Após definida a topologia, ela pode ser executada localmente ou submetida a um cluster (JAIN; NALYA, 2014), (HART; BHATNAGAR, 2015).

Stream é um dos componentes da topologia Storm, definido como uma sequência de tuplas independentes e imutáveis, fornecidas por um ou mais spout e processadas por um ou mais bolt. Cada stream tem o seu respectivo ID, que é utilizado pelos bolts para consumirem e produzirem as tuplas. As tuplas compõem uma unidade básica de dados, suportando os tipos de dados (serializáveis) no qual a topologia está sendo desenvolvida.




Figura 6: Ilustração de uma topologia do Storm

**Fonte:** (JAIN; NALYA, 2014)

**Bolt.** Os bolts são unidades de processamento de dados (streams), sendo eles responsáveis por executar transformações simples sobre as tuplas, as quais são combinadas com outras formando complexas transformações. Também, eles podem ser inscritos para receberem informações tanto de outros bolts, quanto dos spouts, além de produzirem streams como saída (JAIN; NALYA, 2014).

Tais streams são declarados, emitidos para outro bolt e processados, respectivamente, pelos métodos `declareStream`, `emit` e `execute`. As tuplas não precisam ser processadas imediatamente quando chegam a um bolt, pois, talvez haja a necessidade de aguardar para executar alguma operação de junção (`join`) com outra tupla, por exemplo. Também,



inúmeros métodos definidos pela interface `Tuple` podem recuperar metadados associados com a tupla recebida via `execute` (JAIN; NALYA, 2014).

Por exemplo, se um ID de mensagem está associado com uma tupla, o método `execute` deverá publicar um evento `ack`, ou, `fail`, para o bolt, caso contrário o Storm não tem como saber se uma tupla foi processada. Sendo assim, o bolt envia automaticamente uma mensagem de confirmação após o término da execução do método `execute` e, em caso de um evento de falha, é lançada uma exceção (JAIN; NALYA, 2014).

Além disso, num contexto distribuído, a topologia pode ser serializada e submetida, via Nimbus, para um cluster. No qual, será processada por worker nodes. Nesse contexto, o método `prepare` pode ser utilizado para assegurar que o bolt está, após a desserialização, configurado corretamente para executar as tuplas (JAIN; NALYA, 2014), (HART; BHATNAGAR, 2015).

**Spout.** Na topologia Storm um Spout é o responsável pelo fornecimento de tuplas, as quais são lidas e escritas por ele utilizando uma fonte externa de dados (JAIN; NALYA, 2014).

As tuplas emitidas por um spout são rastreadas pelo Storm até terminarem o processamento, sendo emitida uma confirmação ao término dele. Tal procedimento somente ocorre se um ID de mensagem foi gerado na emissão da tupla e, caso esse ID tenha sido definido como nulo, o rastreamento não irá acontecer (JAIN; NALYA, 2014).

Outra opção é definir um timeout a topologia, sendo dessa forma enviada uma mensagem de falha para o spout, caso a tupla não seja processada dentro do tempo estipulado. Sendo necessário, novamente, definir um ID de mensagem. O custo dessa confirmação do processamento ter sido executado com sucesso é a pequena perda de performance, que pode ser relevante em determinados contextos; sendo assim é possível ignorar a emissão de IDs de mensagens (JAIN; NALYA, 2014).

Os principais métodos de um spout são: o `open()`, executado quando o spout é inicializado, sendo nele definida a lógica para acesso a dados de fontes externas; o de declaração de stream (`declareStream`) e o de processamento de próxima tupla (`nextTuple`), que ocorre se houver confirmação de sucesso da tupla anterior (`ack`), sendo o método `fail` chamado pelo Storm caso isso não ocorra (JAIN; NALYA, 2014).

Por fim, nenhum dos métodos utilizados para a construção de um spout devem ser bloqueante, pois o Storm executa todos os métodos numa mesma thread. Além disso, todo

spout tem um buffer interno para o rastreamento dos status das tuplas emitidas, as quais são mantidas nele até uma confirmação de processamento concluído com sucesso (ack) ou falha (fail); não sendo inseridas novas tuplas (via `nextTuple`) no buffer quando ele está cheio (JAIN; NALYA, 2014).

## 3 Definição e execução do estudo de caso

### 3.1 Metodologia de escolha das plataformas para processamento de fluxo de eventos em tempo real

Inicialmente, foi realizada uma pesquisa com a palavra chave "stream processing" e analisados os primeiros artigos (na ordem do resultado e que citavam mais de uma ferramenta) em busca de citações a ferramentas (open source) de processamento de streams em tempo real. Com base nesse resultado, os nomes das plataformas encontradas foram utilizados para buscar a quantidade de referências no Google Scholar (site para publicação de artigos acadêmicos) e Stack Over Flow (site para discussão de assuntos relacionados a desenvolvimento de software). Na Tab. 1, constam os resultados desse procedimento.

A plataforma Esper mencionada em (WÄHNER, 2014) e (KLEPPMANN, 2015). foi descartada do processo de escolha por ser um componente para CEP, normalmente integrado a ferramentas ESPs, fugindo do escopo desse trabalho (ESPERTECH, 2016). Sendo assim, continuando a análise, foram também consideradas as características das opções restantes, estudadas superficialmente nos parágrafos seguintes.

**Apache Spark Streaming.** Apache Spark Streaming é uma extensão do Spark para processamento de stream, em near real time. Além disso, o Spark possui outros módulos para consultas a banco de dados, grafos, e aprendizado de máquina (Apache Software Foundation, 2016f). O processamento de stream é realizado em micro-batching pelo Spark Streaming (um de seus módulos), utilizando uma abstração conhecida como DStream, a qual é composta por uma sequência de RDDs (Resilient Distributed Dataset), ilustrada na Fig. 7. RDDs abstraem uma coleção de dados distribuídos e manipulados em paralelo. No Spark, também é possível utilizar processamento em batch, independente do módulo que está sendo utilizado (KARAU et al., 2015).




Figura 7: Ilustração de um DStream

**Fonte:** (Apache Software Foundation, 2016f)

**Apache Flink.** Apache Flink é um plataforma muito semelhante ao Spark. Com suporte a processamento de streams, os quais são definidos por uma abstração conhecida como `DataStream`, ilustrada na Fig. 8. O processamento em batch é realizado em cima de `DataSets`, semelhantes as `RDDs` do Spak. Da mesma forma como o `DStream` é definido como uma série de `RDDS`, o `DataStream` é composto por uma sequência de `DataSets`. A abstração `Sink` é utilizada para armazenar e retornar `DataSets`. Há suporte também para CEP, processamento em grafos, aprendizado de máquina e consulta a banco de dados (Apache Software Foundation, 2016b).




Figura 8: Ilustração de um fluxo de processamento no Flink

**Fonte:** (DATAARTISANS, 2015)

**Apache Storm.** Apache Storm é um plataforma para processamento de stream em tempo real. Ao contrário do Spark, tem "one at time" como modelo de processamento de dados. As streams são compostas por tuplas (unidade básica de dados, as quais processadas numa abstração conhecida como Topologia, ilustrada na Fig. 6, composta por um DAG (Directed Acyclic Graph (RUOHONEN, 2013)) de spouts e bolts, respectivamente, responsáveis por emitir streams de dados e processá-los (JAIN; NALYA, 2014).

**Apache Samza.** Apache Samza é outra plataforma para processamento de stream em tempo real, utilizando como abstração base o conceito de mensagem (identificadas por offsets, ids), em vez de tupla, ou, `DStream`. Os streams são separados em partições contendo mensagens ordenadas (acessadas apenas no modo de leitura), sendo processados por jobs responsáveis por ler e emitir fluxos. Assim como o Spark, há suporte para processamento em batch, o qual é realizado processando sequências de streams.

Após essas breves descrições das plataformas para processamento de eventos em tempo




Figura 9: Ilustração de um stream particionado no Samza

**Fonte:** (Apache Software Foundation, 2016e)

real e da análise realizada do número de citações, o Spark Streaming e Storm foram escolhidas como ferramentas para o trabalho desenvolvido no Cap. 3. Isso, porque ambas possuem maior número de citações nas fontes pesquisadas, e consequentemente, comunidades maiores, o que pode favorecer melhor documentação, suporte e continuidade desses projetos.

Sendo assim, como Flink e Samza são semelhantes ao Spark o único critério de diferenciação, superficialmente, é o tamanho da comunidade e a popularidade que o Spark tem. No demais, o Storm se diferencia com o conceito de topologia, interessante de ser estudado. Devido a isso, o Spark e Storm foram aprofundados no Cap. 2 e utilizados no trabalho a ser apresentado nesse capítulo.

Tabela 1: Quantidade de citações a plataformas ESPs por referência

<b>Referência</b>	<b>Spark Streaming</b>	<b>Storm</b>	<b>Flink</b>	<b>Samza</b>
(WÄHNER, 2014)	1	1	1	1
(KLEPPMANN, 2015)	1	0	0	1
(Siciliane, T., 2015)	1	1	0	1
(NARSUDE, 2015)	1	1	0	0
(ZAPLETAL, 2015)	1	1	0	0
(SANDU, 2014)	1	1	0	0
(TREAT, 2015)	1	0	0	1
(Google Scholar, 2016)	806	766	171	283
(Stack Over Flow, 2016)	1541	538	567	87
<b>Total de citações</b>	<b>2354</b>	<b>1311</b>	<b>739</b>	<b>374</b>

**Fonte:** Elaboração própria

## 3.2 Aplicações desenvolvidas para estudo de caso

Após a escolha das plataformas para processamento de eventos em tempo real, três aplicações foram desenvolvidas. A primeira, visa processar tweets para coletar métricas relacionadas a e-Participação; a segunda, processa streams de tweets e realiza processamento de linguagem natural para detectar o sentimento expresso neles; a terceira, exibe numa aplicação web um mapa contendo as informações coletadas nas duas anteriores.

### 3.2.1 Aplicação para processamento de tweets e coleta de métricas relacionadas a e-Participação

O primeiro passo no desenvolvimento dessa aplicação, foi decidir as contas das quais os tweets seriam processados. Como, normalmente, as capitais dos estados tem maior concentração de pessoas, optou-se por fazer um levantamento dos perfis oficiais de suas respectivas prefeituras, para então posteriormente realizar o processamento dos tweets. Sendo assim, a Tab. 2 lista as contas relacionadas as prefeituras municipais das capitais dos vinte e sete estados brasileiros.

Em seguida, foram escolhidas quais métricas dessas contas seriam possíveis e importantes de coletar, tendo como referência (SAÉZ-MARTÍN; ROSSARIO; CABA-PEREZ, 2014). Sendo assim, selecionou-se as seguintes, respectivas ao Twitter: média do número de tweets, seguidores, retweets (compartilhamento de um determinado tweet), comentários realizados por usuários, réplicas a tweets e tempo de resposta. As métricas referentes ao número de usuários acompanhando as listas (junções de timelines) do perfil e o total delas existentes foram desconsideradas, pois são relacionadas a contas diferentes das em questão.

De acordo com (SAÉZ-MARTÍN; ROSSARIO; CABA-PEREZ, 2014), através dessas métricas é possível obter indicadores relacionados ao nível e-Participação. Alguns dos indicadores propostos pela SNR (Social Network Ratio) para Redes Sociais são: Atividade, ou, audiência estimada; Tamanho, ou, esforço realizado pelo perfil para se comunicar; Visibilidade, ou, número total de menções ao perfil; Interação, ou, capacidade de impacto (viralização) da comunicação (SAÉZ-MARTÍN; ROSSARIO; CABA-PEREZ, 2014).

Portando, pode-se mapear a métrica média de seguidores ao indicador Atividade, e a de menções para o de Visibilidade; da mesma forma, as médias sobre tweets, réplicas por dia e tempo de resposta ao indicador Tamanho; por último, as médias de retweets e favoritos ao de Interação. A Fig. 10 exibe o diagrama de classes da aplicação desenvolvida para o processamento de tweets e coleta dessas métricas.

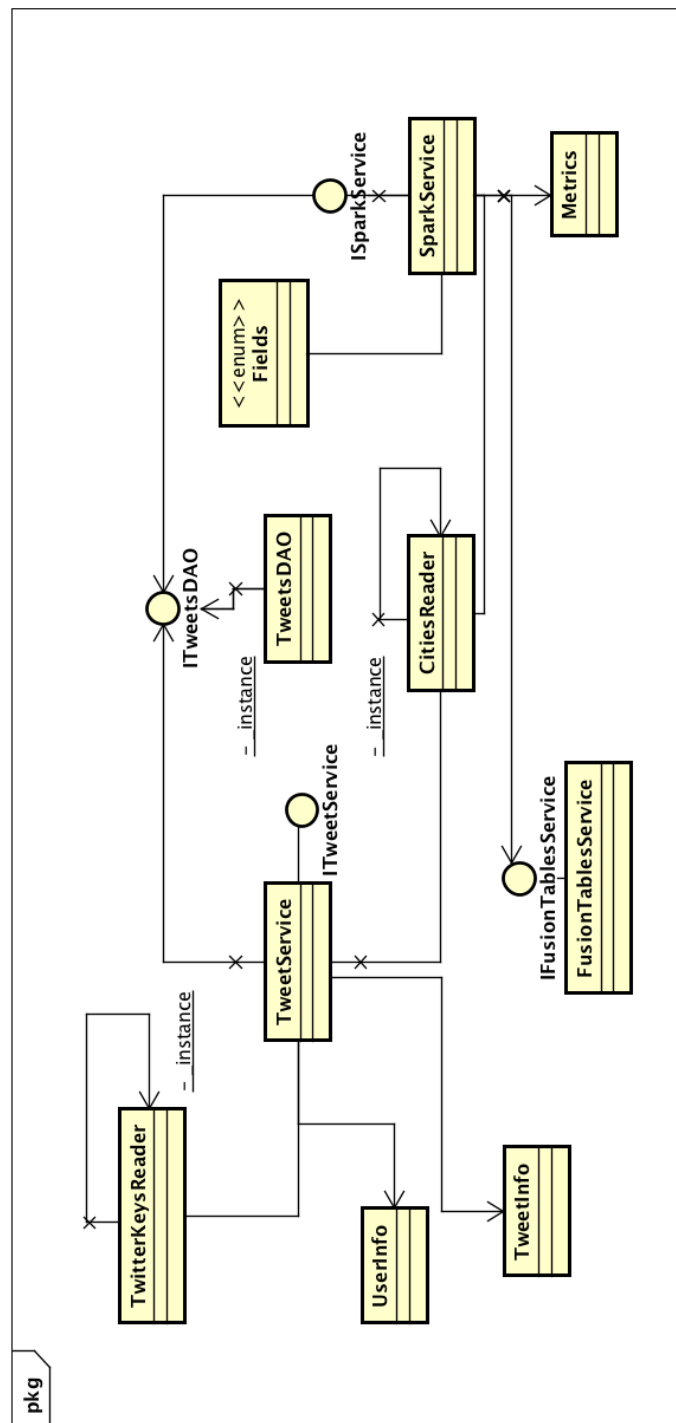


Figura 10: Diagrama de classes da aplicação desenvolvida para processamento e coleta de métricas relacionadas a e-Participação

**Fonte:** Elaboração própria

A aplicação exibida no diagrama de classes da Fig. 10 foi desenvolvida na linguagem de programação Java, devido a sua praticidade de uso, utilizando o framework para Web

services, Apache CXF (Apache Software Foundation, 2016a), para expor dois de seus serviços através de uma REST API. O primeiro deles é exposto pela interface ITweetService, e o segundo pela ISparkService, pelos seguintes endpoints, respectivamente: "\tweets" e "\metrics", permitindo integrá-la a aplicação web descrita na subseção 3.2.2.

A classe que implementa a interface ITweetService, é responsável por realizar a coleta dos 3.200 tweets mais recentes (se disponíveis) de cada conta, através do endpoint "statuses/user\_timeline". Tal quantidade é limitada pela API do Twitter, a qual pode ser alcançada por no máximo 180 requisições, num intervalo de 15 minutos, com autenticação via conta de usuário (TWITTER, 2016).

Outro endpoint utilizado foi "search/tweets", para pesquisar as menções realizadas pelos cidadãos as contas das prefeituras. O limite de coleta é de 100 tweets coletados para cada requisição, sendo possível realizar 180 a cada 15 minutos. Os endpoints da API do Twitter foram acessados com o suporte da biblioteca Twitter4J (TWITTER4J, 2016).

Durante a coleta dos tweets, eles são mapeados para as seguintes classes do modelo da aplicação: UserInfo, que contém as informações respectivas ao usuário da conta (número de seguidores, tweets, localização, username e data de criação da conta), e TweetInfo, contendo as relacionadas ao tweet (data de criação, id do tweet de réplica e a qual usuário ele se refere, quantidade de retweets, favoritos, se é menção ou não, e o tempo de resposta calculado). Em seguida, os modelos são persistidos via a interface ITweetsDAO, a qual se comunica com o banco de dados não relacional MongoDB (MongoDB, 2016).

Os tweets coletados por essa aplicação são os mais recentes e anteriores a data 18/06/2016 (incluindo-a). Como essa coleta não foi realizada sob um stream de tweets, a interface ISparkService expõe o serviço responsável por realizar o processamento em batch desses tweets, coletando as métricas relacionadas a e-Participação. Sendo assim, cada métrica é recuperada do banco de dados e mapeadas para um RDD de doubles, quando números, ou, de strings, no caso da data.




Figura 11: Diagrama do mapeamento entre um Resilient Distributed Dataset de Long para Double

**Fonte:** Elaboração própria



Sendo assim, após recuperar as métricas, é possível mapeá-las para um RDD de doubles, por meio do qual são obtidos os valores relacionados as suas respectivas médias, medianas, variâncias, máximos, mínimos e desvios padrões. As informações sobre datas, como strings, são mapeadas para o valor 1, representando a ocorrência de um tweet nesse dia; compondo uma sequência de pares, que permite obter e mapear as quantidades de tweets por dia a um RDD de doubles. Tais processos de mapeamentos são ilustrados nas Fig. 11 e Fig. 12.

Por fim, a interface IFusionTable é utilizada para submeter os valores das métricas relacionadas e-Participação a uma Fusion Table (DIAS, 2016), via a API do Google Fusion Tables (aplicação web experimental para visualização de dados, coleta e compartilhamento de tabelas (Google, 2016)). Os valores dessa tabela são utilizados para criar o mapa contido na aplicação web.

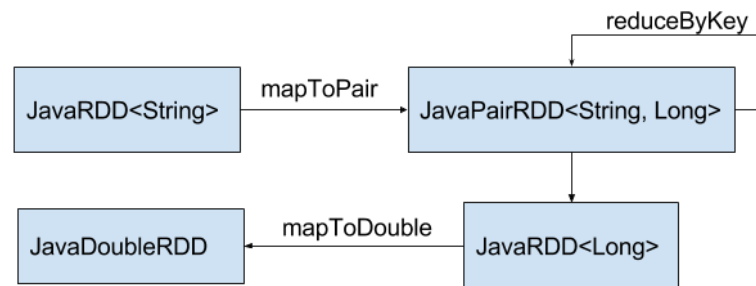


Figura 12: Diagrama do mapeamento entre um Resilient Distributed Dataset de Datas para suas respectivas frequências em Double

**Fonte:** Elaboração própria

### 3.2.2 Aplicação Web

Tabela 2: Contas do Twitter relacionadas as prefeituras municipais das capitais dos vinte e sete estados brasileiros

<b>Estado</b>	<b>Capital</b>	<b>Conta no Twitter</b>
Acre	Rio Branco	PrefRioBranco
Alagoas	Maceió	PrefMaceio
Amapá	Macapá	PMMacapa
Amazonas	Manaus	PrefManaus
Bahia	Salvador	agecomsalvador
Brasília	Brasília	Gov_DF
Ceará	Fortaleza	prefeiturapmf
Espírito Santo	Vitória	VitoriaOnLine
Goiás	Goiânia	PrefeituraGy
Maranhão	São Luís	PrefeituraSL
Mato Grosso	Cuiabá	prefeitura_CBA
Mato Grosso do Sul	Campo Grande	cgnoticias
Minas Gerais	Belo Horizonte	prefeiturabh
Paraná	Curitiba	Curitiba_PMC
Paraíba	João Pessoa	pmjponline
Pará	Belém	prefeiturabelem
Pernambuco	Recife	prefrecife
Piauí	Teresina	prefeitura_the
Rio Grande do Norte	Natal	NatalPrefeitura
Rio Grande do Sul	Porto Alegre	Prefeitura_POA
Rio de Janeiro	Rio de Janeiro	Prefeitura_Rio
Rondônia	Porto Velho	prefeitura_pvh
Roraima	Boa Vista	PrefeituraBV
Santa Catarina	Florianópolis	scflorianopolis
Sergipe	Aracaju	PrefeituraAracaju
São Paulo	São Paulo	prefsp
Tocantins	Palmas	cidadepalmas

**Fonte:** Elaboração própria

## 4 Capítulo 4

### 4.1 Seção 1

Teste para símbolo

$\lambda$

### 4.2 Seção 2

Teste para abreviatura

UFRN

DIMAp

## 5 Capítulo 5

### 5.1 Seção 1

Seção 1

### 5.2 Seção 2

#### 5.2.1 Subseção 5.1

Subseção 5.1

#### 5.2.2 Subseção 5.2

Subsection 5.2

### 5.3 Seção 3

Seção 3

## 6 Considerações finais

As considerações finais formam a parte final (fechamento) do texto, sendo dito de forma resumida (1) o que foi desenvolvido no presente trabalho e quais os resultados do mesmo, (2) o que se pôde concluir após o desenvolvimento bem como as principais contribuições do trabalho, e (3) perspectivas para o desenvolvimento de trabalhos futuros. O texto referente às considerações finais do autor deve salientar a extensão e os resultados da contribuição do trabalho e os argumentos utilizados estar baseados em dados comprovados e fundamentados nos resultados e na discussão do texto, contendo deduções lógicas correspondentes aos objetivos do trabalho, propostos inicialmente.

# Referências

- Apache Software Foundation. *Apache CXF*. 2016. Disponível em: <<http://cxf.apache.org>>. Acesso em Maio 20, 2016.
- Apache Software Foundation. *Apache Flink*. 2016. Disponível em: <<http://flink.apache.org>>. Acesso em Maio 7, 2016.
- Apache Software Foundation. *Apache Hadoop YARN*. 2016. Disponível em: <<http://hadoop.apache.org>>. Acesso em Abril 22, 2016.
- Apache Software Foundation. *Apache Mesos*. 2016. Disponível em: <<http://mesos.apache.org>>. Acesso em Abril 23, 2016.
- Apache Software Foundation. *Apache Samza*. 2016. Disponível em: <<http://samza.apache.org>>. Acesso em Maio 06, 2016.
- Apache Software Foundation. *Apache Spark*. 2016. Disponível em: <<http://spark.apache.org>>. Acesso em Abril 22, 2016.
- Apache Software Foundation. *Apache Storm*. 2016. Disponível em: <<http://storm.apache.org>>. Acesso em Abril 30, 2016.
- Apache Software Foundation. *Apache Thrift*. 2016. Disponível em: <<http://thrift.apache.org>>. Acesso em Abril 30, 2016.
- Apache Software Foundation. *Apache ZooKeeper*. 2016. Disponível em: <<https://zookeeper.apache.org>>. Acesso em Abril 30, 2016.
- CISCO. *Internet of Everything*. 2016. Disponível em: <<http://ioeassessment.cisco.com/pt-br>>. Acesso em Maio 07, 2016.
- CLARKE, R. *Smart Cities and the Internet of Everything: The Foundation for Delivering Next Generation CitizenServices*. 2013. Disponível em: <<http://www.cisco.com>>. Acesso em Maio 07, 2016.
- Connected Smartcities. *Ranking Connected Smartcities*. 2015. Disponível em: <<http://www.connectedsmartcities.com.br>>. Acesso em Maio 08, 2016.
- COULOURIS, G. et al. *Sistemas Distribuídos Conceitos e Projetos*. 5st. ed. [S.l.]: Bookman, 2013.
- DATAARTISANS. *Apache Flink Training - System Overview*. 2015. Disponível em: <<http://pt.slideshare.net>>. Acesso em Maio 7, 2016.
- DIAS, F. *Brazilian Smart Cities e-Participation Metrics based on Twitter*. 2016. Disponível em: <<https://goo.gl/0I3Vgj>>. Acesso em Maio 20, 2016.

EMC. *The Digital Universe of Opportunities: Rich Data and the Increasing Value of the Internet of Things*. 2014. Disponível em: <<https://www.emc.com>>. Acesso em Maio 11, 2016.

ESPERTECH. 2016. Disponível em: <<http://www.espertech.com>>. Acesso em Maio 7, 2016.

Google. *Google Fusion Tables*. 2016. Disponível em: <<http://tables.googlelabs.com>>. Acesso em Maio 20, 2016.

Google Scholar. 2016. Disponível em: <<https://scholar.google.com>>. Acesso em Maio 7, 2016.

H., M. et al. *Special section on smart grids: A hub of interdisciplinary research*. 2016.

HARDIN, G. A vision of social media in the spanish smartest cities. *Science*, v. 162, 1968. Disponível em: <<http://science.sciencemag.org>>. Acesso em Maio 08, 2016.

HART, B.; BHATNAGAR, K. *Building Python Real-Time Applications with Storm*. 1st. ed. [S.l.]: Packt Publishing, 2015.

INFOPEDIA. *Tweet*. 2016. Disponível em: <<http://www.infopedia.pt>>. Acesso em Maio 08, 2016.

JAIN, A.; NALYA, A. *Learning Storm*. 1st. ed. [S.l.]: Packt Publishing, 2014.

KARAU, H. et al. *Learning Spark*. 1st. ed. [S.l.]: O'Reilly Media, 2015.

KLEPPMANN, M. *Stream processing, Event sourcing, Reactive, CEP? and making sense of it all*. 2015. Disponível em: <<http://www.confluent.io>>. Acesso em Maio 7, 2016.

LUCKHAM, D. *What's the Difference Between ESP and CEP?* 2006. Disponível em: <<http://www.complexevents.com>>. Acesso em Maio 7, 2016.

MACIEL, C.; ROQUE, L.; GARCIA, A. *Democratic Citizenship Community: a social network to promote e-Deliberative process*. 2009.

MAGALHÃES, L. *Instâncias e mecanismos de participação em ambientes virtuais: análise das experiências de participação política online em políticas públicas*. 2015. 39º Encontro Anual da Associação Nacional de Pós-Graduação e Pesquisa em Ciências Sociais.

MongoDB. 2016. Disponível em: <<https://www.mongodb.com>>. Acesso em Maio 20, 2016.

NARSUDE, C. *Real-Time Event Stream Processing ? What are your choices?* 2015. Disponível em: <<https://www.datatorrent.com>>. Acesso em Maio 5, 2016.

ONU. *World Urbanization Prospects The 2014 Revision*. 2014. Disponível em: <<http://esa.un.org>>. Acesso em Maio 10, 2016.

PRIBERAM. *Definição de deliberação*. 2016. Disponível em: <<https://www.priberam.pt>>. Acesso em Maio 14, 2016.

- RUOHONEN, K. *Graph Teory*. 2013. Disponível em: <[http://math.tut.fi/~ruohonen/GT\\_English.pdf](http://math.tut.fi/~ruohonen/GT_English.pdf)>. Acesso em Maio 01, 2016.
- SANDU, D. *Without stream processing, there?s no big data and no Internet of things*. 2014. Disponível em: <<http://venturebeat.com>>. Acesso em Maio 7, 2016.
- SAÉZ-MARTÍN, A.; ROSSARIO, A. Haro-de; CABA-PEREZ, C. A vision of social media in the spanish smartest cities. *Transforming Government: People, Process and Policy*, v. 8, n. 4, 2014.
- SHIN, K. G.; RAMANATHAN, P. Real-time computing: A new discipline of computer science and engineering. *Procedings og the IEEE*, v. 82, n. 1, 1994.
- Siciliane, T. *Streaming Big Data: Storm, Spark and Samza*. 2015. Disponível em: <<https://dzone.com>>. Acesso em Maio 7, 2016.
- SOMMERVILLE, I. *Engenharia de Software*. 9th. ed. [S.l.]: Pearson, 2011.
- Stack Over Flow. 2016. Disponível em: <<https://http://stackoverflow.com>>. Acesso em Maio 7, 2016.
- Techopedia. 2016. Disponível em: <<https://www.techopedia.com>>. Acesso em Abril 23, 2016.
- TREAT, T. *Stream Processing and Probabilistic Methods: Data at Scale*. 2015. Disponível em: <<http://bravenewgeek.com>>. Acesso em Maio 7, 2016.
- TWITTER. *Twitter Developers*. 2016. Disponível em: <<https://dev.twitter.com>>. Acesso em Maio 20, 2016.
- TWITTER4J. 2016. Disponível em: <<http://twitter4j.org/>>. Acesso em Maio 20, 2016.
- WÄHNER, K. *Real-Time Stream Processing as Game Changer in a Big Data World with Hadoop and Data Warehouse*. 2014. Disponível em: <<http://www.infoq.com>>. Acesso em Maio 7, 2016.
- XU, L.; JU, H.; REN, H. *Gitbook: SparkInternals*. 2015. Disponível em: <<https://github.com/JerryLead/SparkInternals>>. Acesso em Abril 30, 2016.
- ZAPLETAL, P. *Introduction Into Distributed Real-Time Stream Processing*. 2015. Disponível em: <<http://www.cakesolutions.net>>. Acesso em Maio 7, 2016.



## APÊNDICE A – Primeiro apêndice

Os apêndices são textos ou documentos elaborados pelo autor, a fim de complementar sua argumentação, sem prejuízo da unidade nuclear do trabalho.

## ANEXO A – Primeiro anexo

Os anexos são textos ou documentos não elaborado pelo autor, que servem de fundamentação, comprovação e ilustração.